

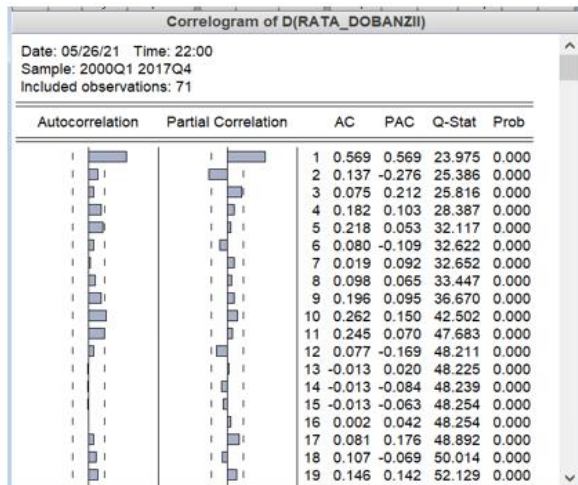
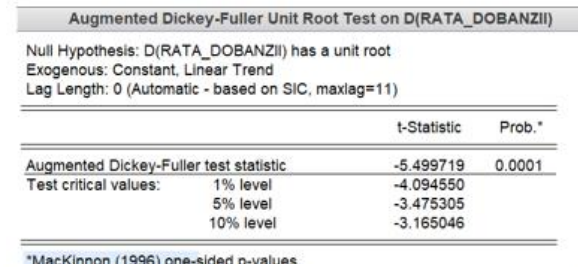
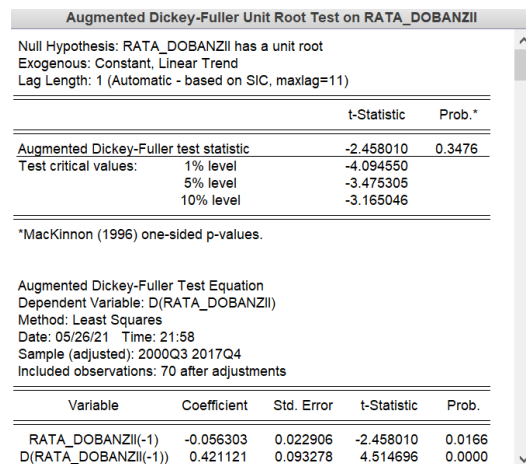
# Examen Serii de timp-Anul III Informatica Economica

15 iunie 2021

Prof.univ.dr. Davidescu Adriana AnaMaria

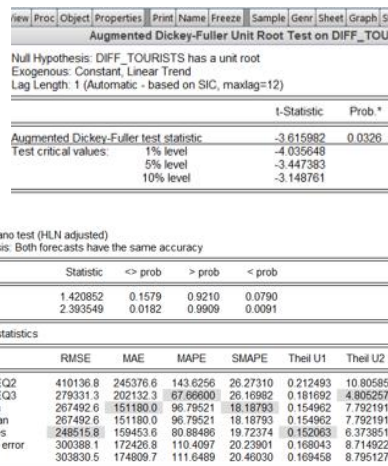
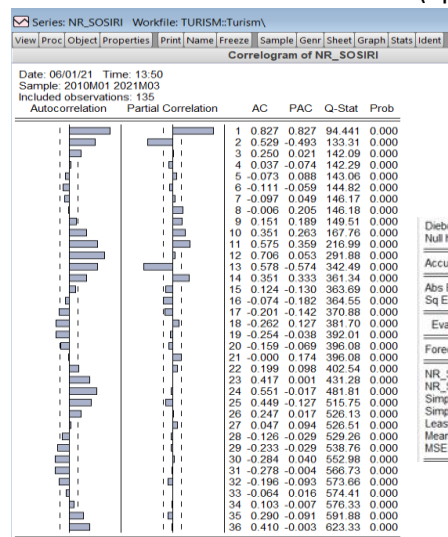
Of.1p

## 1.Fie seria ratei dobanzii pentru Romania(1p)




- Sa se analizeze stationaritatea seriei pe baza testului ADF(fig.st). Aceasta serie poate fi considerata si nestationara? Ce transformari trebuie operate pentru a deveni stationara?
- Sa se identifice tipul de proces urmat pe baza outputului din Eviews de seria originala GDP(fig.dr.), sa se scrie ecuatia tipului de proces.Justificati raspunsul.

## 2 .Se da seria numarului de turisti (1p)



ADF pentru seria diferențiată sezonier



- Prezinta seria sezonalitate? Motivati raspunsul.
- Este seria nestationara? Daca da, cum ar putea fi stationarizata.
- Evaluati calitatea prognozei pe baza rez. DM.

3. Se dau urmatoarele informatii referitoare la seria pretului de inchidere a companiei Amazon(0.5p)

	R_squared	Akaike	Schwartz
AR(4) MA(4)	0,93	4,48	4,6
AR(3) MA(3)	0,33	6,68	6,81
AR(4) MA(3)	0,91	4,65	4,77
AR(3) MA(4)	0,63	6,05	6,17
AR(4) SAR(4) MA(3)	0,95	6,18	6,32
AR(3) SAR(4) MA(3)	0,92	4,67	4,82
AR(3) SAR(4) MA(1)	0,92	4,58	4,72
AR(4) SAR(4) MA(1)	0,93	4,43	4,58

Heteroskedasticity Test: ARCH

F-statistic	0.434914	Prob. F(12,350)	0.9489
Obs*R-squared	5.333295	Prob. Chi-Square(12)	0.9459



- Determinati modelul optim urmat de **seria originala** si scrieti ecuatia acestuia. Justificati alegerea.
- Analizand rez. Testului ARCH ce concluzie puteti desprinde?(fig.st.)

4. Pentru seria valorii exporturilor ca % din PIB, se ofera urmatoarele informatii(1.25p)

Correlogram of D(EXPORT\_)

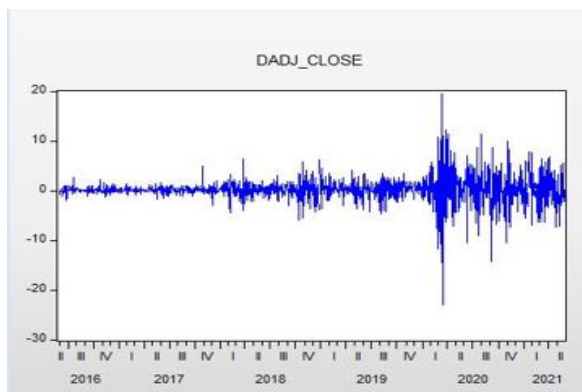
Date: 05/22/21 Time: 11:18  
Sample: 2000Q1 2020Q4  
Included observations: 83

Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob
1	-0.369	-0.369	11.734	0.001	
2	-0.229	-0.423	16.312	0.000	
3	-0.328	-0.853	25.798	0.000	
4	0.903	0.502	98.555	0.000	
5	-0.343	0.143	109.18	0.000	
6	-0.216	0.076	113.46	0.000	
7	-0.306	-0.088	122.15	0.000	
8	0.850	0.124	190.12	0.000	
9	-0.333	0.011	200.57	0.000	
10	-0.199	0.042	204.49	0.000	
11	-0.288	-0.024	212.61	0.000	
12	0.789	-0.063	274.51	0.000	
13	-0.303	0.038	283.75	0.000	
14	-0.185	0.038	287.26	0.000	
15	-0.267	0.058	294.66	0.000	
16	0.729	-0.006	350.55	0.000	
17	-0.282	-0.015	359.06	0.000	
18	-0.172	-0.027	362.28	0.000	
19	-0.247	-0.007	369.03	0.000	
20	0.670	-0.046	419.26	0.000	
21	-0.262	-0.059	427.09	0.000	
22	-0.149	0.023	429.66	0.000	
23	-0.235	-0.008	436.16	0.000	
24	0.623	0.048	482.60	0.000	
25	-0.252	-0.026	490.31	0.000	
26	-0.133	-0.036	492.49	0.000	
27	-0.211	0.024	498.12	0.000	
28	0.551	-0.078	538.53	0.000	
29	-0.228	-0.012	545.33	0.000	
30	-0.113	0.003	547.05	0.000	



- Ce transformari a suferit seria pentru a dobandi stationaritatea si care este seria stationara?
- Identificati tipul de proces urmat de seria originala si scrieti ecuatia tipului de proces.Motivati raspunsul.
- Caracterizati acuratetea prognozelor realizate, mentionand care prognoza ofera rezultate mai bune.

5. Fie randamentul pretului de inchidere al indicelui S&P500 (1.25p)



Dependent Variable: DADJ\_CLOSE  
Method: ML ARCH - Normal distribution (BFGS / Marquardt steps)  
Date: 06/01/21 Time: 16:20  
Sample (adjusted): 6/01/2016 5/28/2021  
Included observations: 1258 after adjustments  
Convergence achieved after 123 iterations  
Coefficient covariance computed using outer product of gradients  
Presample variance: backcast (parameter = 0.7)  
GARCH = C(3) + C(4)\*RESID(-1)^2 + C(5)\*GARCH(-1)

Variable	Coefficient	Std. Error	z-Statistic	Prob.
DATE	0.000167	7.36E-05	2.275658	0.0229
C	-123.2548	54.21683	-2.273368	0.0230

Variance Equation				
C	0.032159	0.004280	7.513982	0.0000
RESID(-1)^2	0.155781	0.016464	9.461698	0.0000
GARCH(-1)	0.849642	0.014354	59.19029	0.0000

R-squared	0.000692	Mean dependent var	0.159661
Adjusted R-squared	-0.000103	S.D. dependent var	2.582050
S.E. of regression	2.582184	Akaike info criterion	3.723303
Sum squared resid	8374.598	Schwarz criterion	3.743722
Log likelihood	-2336.958	Hannan-Quinn criter.	3.730977
Durbin-Watson stat	2.528533		

Heteroskedasticity Test: ARCH

F-statistic	0.005486	Prob. F(1,1255)	0.9410
Obs*R-squared	0.005495	Prob. Chi-Square(1)	0.9409

- Este seria originala nestationara?
- Ce particularitate are aceasta serie?
- Sa se identifice si sa se scrie ecuatia modelului urmat de seria analizata. Sa se analizeze bonitatea unui astfel de model.
- Sa se precizeze daca acesta poate fi validat pe considerente multicriteriale.

6. Fie seria de timp  $y_t = 0.8 + y_{t-1} + \varepsilon_t$ ,  $\varepsilon_t$  este  $WN(0,4)$ . Calculati varianta si functia de autocorelatie si aratati ca seria este una nestationara(1p)

- A fost investigata relatia dintre pretul petrolului, pretul motorinei, cursul de schimb si indicele de pret "the Economist" (3p)
  - Care este lagul optim al modelului? Justificati raspunsul.
  - Cate relatii de echilibru pe termen lung pot fi considerate pe baza testului Johansen?
  - Scrietii modelul VECM din tabelul de mai sus si comentati existenta echilibrului intre variabile
  - Exista cauzalitate Granger pe termen lung intre variabile? Justificati.
  - Interpretati economic rezultatele pe termen lung si pe termen scurt si cuantificati impactul pretului petrolului si a cursului de schimb asupra pretului motorinei pe termen scurt.
  - Cum explicati dinamicile propagate de IRF? Carui factor economic se pot datora ele? Cum se pot explica socurile in varianta erorii de prognoza?
  - Propuneti solutii de imbunatatire ale modelului care sa tina cont de impactul pandemiei de COVID-19.

Series: LOG(MOTORINA1) LOG(PRET\_PETROL) LOG(CURS\_SCHIMB) LOG(TH...  
Exogenous series: COVID\_19  
Warning: Critical values assume no exogenous series  
Lags interval (in first differences): 1 to 1

Unrestricted Cointegration Rank Test (Trace)


Hypothesized No. of CE(s)	Eigenvalue	Trace Statistic	0.05 Critical Value	Prob.**
None *	0.186767	94.77457	54.07904	0.0000
At most 1 *	0.068927	37.30138	35.19275	0.0292
At most 2	0.043055	17.44725	20.26184	0.1167
At most 3	0.018576	5.212724	9.164546	0.2609

Vector Error Correction Estimates  
Date: 06/15/21 Time: 14:09  
Sample (adjusted): 3 280  
Included observations: 278 after adjustments  
Standard errors in ( ) & t-statistics in [ ]


Cointegrating Eq:		CointEq1			
LOG(MOTORINA1(-1))		1.000000			
LOG(PRET_PETROL(-1))		-0.657530 (0.04499) [-14.6156]			
LOG(CURS_SCHIMB(-1))		-0.607915 (0.19208) [-3.16486]			
LOG(THE_EC_PRICE_I...		-0.269371 (0.13643) [-1.97444]			
C		-2.362351 (0.64813) [-3.64489]			
Error Correction:		D(LOG(MOT...	D(LOG(PRE...	D(LOG(CUR...	D(LOG(THE...
CointEq1		-0.112986 (0.02076) [-5.44247]	0.289474 (0.07077) [4.09057]	-0.002593 (0.01467) [-0.17679]	-0.005094 (0.02380) [-0.21404]
D(LOG(MOTORINA1(-1)))		0.199335 (0.05148) [3.87206]	0.045329 (0.17548) [0.25831]	-0.058784 (0.03637) [-1.61610]	0.042709 (0.05902) [0.72364]
D(LOG(PRET_PETROL(...		0.081559 (0.01940) [4.20302]	0.130799 (0.06615) [1.97742]	-0.014601 (0.01371) [-1.06491]	0.010213 (0.02225) [0.45910]
D(LOG(CURS_SCHIMB...		0.053491 (0.08566) [0.62448]	-0.234847 (0.29198) [-0.80432]	-0.055763 (0.06052) [-0.92138]	0.072766 (0.09820) [0.74099]
D(LOG(THE_EC_PRIC...		-0.006147 (0.05152) [-0.11931]	-0.141748 (0.17563) [-0.80710]	-0.071444 (0.03640) [-1.96257]	-0.337780 (0.05907) [-5.71854]
COVID_19		0.005063 (0.00661) [0.76588]	-0.115222 (0.02253) [-5.11308]	-0.001921 (0.00467) [-0.41126]	0.006347 (0.00758) [0.83742]
R-squared		0.340571	0.113025	0.032770	0.116005
Adj. R-squared		0.328449	0.096720	0.014990	0.099755
Sum sq. resids		0.078836	0.916053	0.039357	0.103619
S.E. equation		0.017025	0.058033	0.012029	0.019518
F-statistic		28.09557	6.932038	1.843088	7.138824
Log likelihood		740.8877	399.9621	837.4495	702.8924
Akaike AIC		-5.286962	-2.834260	-5.981651	-5.013615
Schwarz SC		-5.208668	-2.755966	-5.903357	-4.935321
Mean dependent		-0.000730	-0.002025	0.000285	-0.000381
S.D. dependent		0.020775	0.061061	0.012120	0.020571

## Response to Nonfactorized One S.D. Innovations

### Response of LOG(MOTORINA1) to LOG(PRET\_PETROL)



### Response of LOG(CURS\_SCHIMB) to LOG(PRET\_PETROL)



Period	S.E.	LOG(MOTO...	LOG(PRET...	LOG(CUR...	LOG(THE_...
1	0.017025	100.0000	0.000000	0.000000	0.000000
2	0.028074	89.48382	10.22803	0.261134	0.027014
3	0.037170	81.05357	18.59940	0.330750	0.016278
4	0.044885	75.07922	24.54402	0.362153	0.014606
5	0.051656	70.74710	28.85196	0.387150	0.013790

Cholesky Ordering: LOG(MOTORINA1) LOG(PRET\_PETROL) LOG(CURS\_...

## Examen Serii de timp

1.

a) Ipotezele testului ADF:

$H_0$ : seria are rădăcină unitară și este nestaționară

$H_1$ : seria este staționară

Din output-ul testului ADF, se observă  $t_{calc} > t_{critic}$  pentru toate nivelurile de semnificație:

$$1\% - |t_{calc}| = 4,09 > t_{critic} = -2.47$$

$$5\% - |t_{calc}| = 3,47 > t_{critic} = -2.47$$

$$10\% - |t_{calc}| = 3,16 > t_{critic} = -2.47,$$

concluzionând că seria este nestaționară.

În plus,  $prob = 0,347 > 0,05$  susține nestaționaritatea seriei.

Pentru ca seria să devină staționară, acesteia i se stabilește prima diferență:

$$RATA\_DOBANZII = D(RATA\_DOBANZII)$$

Următorul pas este reprezentat de verificarea testelor de staționaritate ADF și PP. În output-ul din dreapta sus se poate observa rezultatul testului Augmented Dickey-Fuller după diferențiere. Întrucât  $prob = 0,0001 < 0,05$  și  $t_{calc} < t_{critic}$ , pentru toate nivele de semnificație, putem concluziona că seria diferențiată este staționară, acceptând astfel ipoteza alternativă.

b) Din analiza corelogramei identificăm următoarele modele:

$$IAR(1) = D(RRATA\_DOBANZII) = C + AR(1),$$

$$ARIMA(1, 1, 2) = D(RATA\_DOBANZII) = C + AR(1) + MA(2)$$

$$ARIMA(1, 1, 1) = D(RATA\_DOBANZII) = C + AR(1) + MA(2)$$

Acestea trebuie comparate și testate din punct de vedere al semnificației parametrilor și a validității modelelor.

.2.

- a) Prin studiul dispunerii lag-urilor corelogramei, se poate observa un șablon pe care valorile AC respectiv PAC îl urmează, aceste 2 variabile oscilând periodic din 12 în 12 luni, prin urmare, putem concluziona că seria numărului de turiști prezintă sezonaliitate.
- b) Analizând corelograma seriei putem observa absența unei tendințe descendente în coloana AC. În urma neidentificării unui șablon vizibil, se poate formula concluzia că seria este nestaționară. Pentru a staționariza seria, i se poate aplica operatorul de diferențiere sezonier.

Astfel, în output-ul testului ADF se observa  $prob = 0,03 < 0,05$ , concluzionând că diferențierea sezonieră a staționarizat seria de date.

3.

- a) Pentru a determina cel mai bun model, avem nevoie de:

$$\max(R - squared) = AR(4) SAR(4) MA(3)$$

$$\min(AIC) = AR(4) SAR(4) MA(1)$$

$$\min(Schwartz) = AR(4) SAR(4) MA(1),$$

Astfel, putem concluziona că cel mai bun model este **AR(4) SAR(4) MA(1)**

b) Ipotezele testului ARCH

$H_0$ : erorile sunt homoschedastice

$H_1$ : erorile sunt heteroschedastice

Întrucât în output se observă  $prob = 0,94 > 0,05$ , putem accepta ipoteza nulă conform căreia erorile sunt homoschedastice.

4.

- a) Pentru a staționariza seria, aceasta a fost diferențiată  $EXPORT\_DIFF = D(EXPORT\_)$
- b) Seria originală poate urma un proces de tipul ISMA(1, 3) sau SARIMA(4, 1, 3). Acestea trebuie comparate pentru a putea stabili modelul optim.
- c) EXPORTF6 are o valoare foarte apropiată de 0 a indicelui Theil Inequality Coef, mai exact 0,02, lucru ce semnifică faptul că valorile previzionate sunt apropiate de valorile reale.

În ceea ce privește acuratețea Bias Porportion, ce ia valoarea 0,001, aceasta indică faptul că predicția are o acuratețe foarte bună, fapt susținut și de valoarea apropiată de 1 a coeficientului Covariance Proportion.

Analizând și prognoza dinamică, aceasta are o acuratețe mult mai slabă comparativ cu predicția analizaă anterior (Bias Proportion are o valoare mare, în timp de Covariance Proportion tinde către 0).

5.

- a) Conform graficului, seria originală nu este staționară, fapt ce se datorează fluctuațiilor puternice ale lui S&P500. Astfel, seria este nestaționară în medie.
- b) Seria inițială este una financiară, astfel că folosim modelul de valori ARCH/GARCH care, pe baza reziduurilor, ne poate ajuta să clusterizăm pentru alegerea modelului optim.
- c) Ecuația modelului este:

$$GARCH = C(3) * C(4) * RESID(-1)^2 + C(5) * GARCH(-1),$$

Din output, putem înlocui:

$$GARCH = 0,032 + 0,155 * RESID(-1)^2 + 0,849 * GARCH(-1)$$

- d) Din output-ul modelului, observăm următoarele:

$$R^2 = 0,00069,$$

coeficienții sunt semnificativi statistic, având „prob” < 0,05 (0,02, respectiv 0,023)

AIC, Schwartz și H – Q au valori mici

Astfel, putem concluziona că modelul poate fi validat pe considerente multicriteriale.

$$6. y_t = 0.8 + y_{t-1} + \varepsilon_t$$

$$y_{t-1} = 0.8 + y_{t-2} + \varepsilon_{t-1}$$

...

$$y_1 = 0.8 + y_0 + \varepsilon_1$$

$$y_t = 0.8 + y_0 + \varepsilon_1 + \varepsilon_2 + \dots + \varepsilon_n \Rightarrow E(t) = 0,8 * t + y_0 \Rightarrow Var(y_t) = 0,8 * 4t$$

7.

- a) Lag-ul optim al modelului este lag-ul 1, lucru ce se poate observa în primul output.
- b) Testul Johansen prezintă următoarele ipoteze:

$H_0$ : nu există relație de cointegrare

$H_1$ : există relație de cointegrare

Pentru *Trace statistic* > *Critical Value* putem afirma ca exista relatie de echilibru:

*None* \* : 94.77 > 54.07

*At most 1* \* : 37.03 > 35.19

*At most 2*: 17.44 < 20.26

*At most 3*: 5.212724 < 9.164546

Astfel, putem afirma că exista relație de echilibru doar in cazul lag-urilor 0 si 1.

- c) Modelul VECM  
 Ecuația pe termen lung:

$$\begin{aligned} LOG(MOTORINA1(-1)) \\ = -2.36 - 0.65 * LOG(PRET_{PETROL}(-1)) - 0.6 * LOG(CURS_{SCHIMB}(-1)) \\ - 0.26 * LOG(TH_{ECPRICEINDEX}(-1)) \end{aligned}$$

- d) Cauzalitatea Granger testează dacă o variabilă explicativă poate fi tratată ca și explicator. Putem afirma cp exist cauzalitate Granger între variabila MOTORINA și PRET\_PETROL, datorită faptului că testul t are valori 5,44 și 4,09 (ambele în modul) > 2 (valoare ce se poate observa la CointEq1)